# Лекции 17-18 «Проектирование высоконагруженных и аналитических систем»

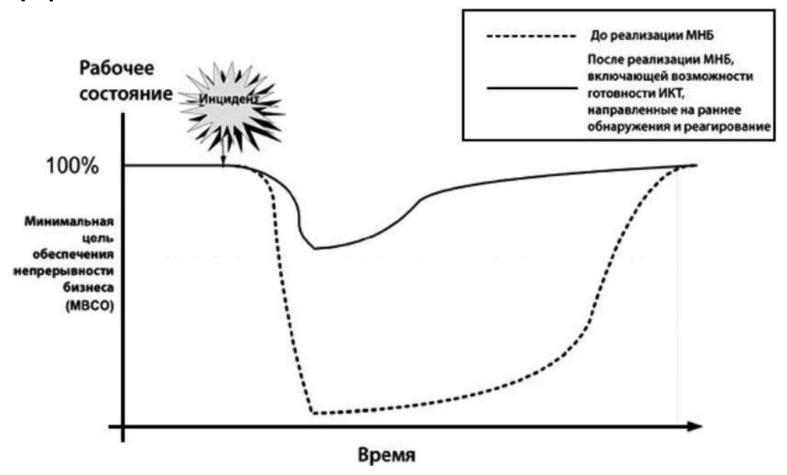
Овчинников П.Е. МГТУ «СТАНКИН», ст.преподаватель кафедры ИС

# Лекция 17 «Высоконагруженные системы и системы реального времени»

Овчинников П.Е. МГТУ «СТАНКИН», ст.преподаватель кафедры ИС

#### Терминология: непрерывность бизнеса

ГОСТ Р ИСО/МЭК 27031-2012 Информационная технология (ИТ). Методы и средства обеспечения безопасности. Руководство по готовности информационно-коммуникационных технологий к обеспечению непрерывности бизнеса



#### Терминология: высокая доступность

ГОСТ Р ИСО/МЭК 27031-2012 Информационная технология (ИТ). Методы и средства обеспечения безопасности. Руководство по готовности информационно-коммуникационных технологий к обеспечению непрерывности бизнеса

В информационно-коммуникационных технологиях "высокая доступность" относится к системам или компонентам, которые непрерывно функционируют в течение желаемого длительного периода времени

Доступность может измеряться по отношению к "100% работоспособности" или "полному отсутствию отказов". Существует широко распространенный, но труднодостижимый эталон доступности систем или продуктов, известный как "пять девяток" (99,999%) доступности

Компьютерная система или сеть состоит из многих компонентов, каждый из которых должен быть в наличии и быть функциональным, чтобы все в целом было работоспособным, и, хотя планирование высокой доступности часто сосредотачивается на резервировании, обработке отказа, хранении данных и доступе к ним, другие компоненты инфраструктуры, такие как энергоснабжение и охлаждение, являются в равной степени важными

#### Терминология: высоконагруженные системы

Высоконагруженные приложения. Программирование, масштабирование, поддержка



#### Источники нагрузки:

- пользователи
- роботы
- приложения

#### Нагрузка:

- трафик
- оперативная память
- процессор
- дисковая память

#### Негативные последствия:

- замедление работы
- потеря данных
- отказ в обслуживании (DoS)

### HighLoad: оптимизация трафика

#### Подходы к описанию сетевого трафика

"Классические" методы сетевых расчетов и моделирования, основанные на пуассоновских моделях, предполагали, что все поступившие в исследуемую систему вызовы взаимно независимы и интервалы времени между приходом двух последующих вызовов распределены согласно экспоненциальному закону.

В то же время самоподобный трафик обладает медленно убывающей автокорреляционной функцией, плотность распределения вероятности интервалов между моментами прихода двух последовательных вызовов подчиняется степенному закону

Одно из важных свойств самоподобия трафика - сохранение своей структуры в разные масштабы времени

Из-за таких свойств самоподобного трафика традиционные методы расчета характеристик функционирования сетей дают слишком оптимистические результаты и приводят к недооценке реальной нагрузки

<u>IP-коммуникации</u>

#### HighLoad: кэширование

**Кэш** или **кеш** (<u>англ.</u> *cache*, от <u>фр.</u> *cacher* — «прятать»; произносится [kæʃ] — «кэш») — промежуточный <u>буфер</u> с **быстрым доступом** к нему, содержащий информацию, которая может быть запрошена с **наибольшей вероятностью** 

Доступ к данным в кэше осуществляется быстрее, чем выборка исходных данных из более медленной памяти или удаленного источника, однако её объём существенно ограничен по сравнению с хранилищем исходных данных

Кэширование применяется <u>ЦПУ</u>, <u>жёсткими дисками</u>, <u>браузерами</u>, <u>веб-серверами</u>, службами <u>DNS</u> и <u>WINS</u>

Когда клиент кэша обращается к данным, прежде всего исследуется кэш:

- если в кэше найдена запись с идентификатором, совпадающим с идентификатором затребованного элемента данных, то используются элементы данных в кэше. Такой случай называется *попаданием кэша*
- если в кэше не найдена запись, содержащая затребованный элемент данных, то он читается из основной памяти в кэш, и становится доступным для последующих обращений. Такой случай называется *промахом кэша*

Процент обращений к кэшу, когда в нём найден результат, называется *уровнем* попаданий, или коэффициентом попаданий в кэш.

<u>Кэш (Википедия)</u>

#### HighLoad: балансировка нагрузки

В терминологии компьютерных сетей балансировка нагрузки или выравнивание нагрузки (англ. load balancing) — метод распределения заданий между несколькими сетевыми устройствами (например, серверами) с целью оптимизации использования ресурсов, сокращения времени обслуживания запросов, горизонтального масштабирования кластера (динамическое добавление/удаление устройств), а также обеспечения отказоустойчивости (резервирования)

В компьютерах балансировка нагрузки распределяет нагрузку между несколькими вычислительными ресурсами, такими как компьютеры, компьютерные кластеры, сети, центральные процессоры или диски

#### Цель балансировки нагрузки:

- оптимизация использования ресурсов
- максимизация пропускной способности
- уменьшение времени отклика
- предотвращение перегрузки какого-либо одного ресурса

Использование нескольких компонентов балансировки нагрузки вместо одного компонента может повысить надежность и доступность за счет резервирования.

#### HighLoad: управление блокировками

#### Ведущий узел и блокировки

Зачастую системе необходимо наличие только одного экземпляра чего-либо, например:

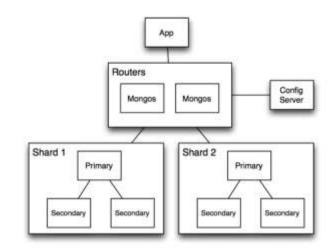
- только один узел может быть ведущим для секции базы данных, чтобы избежать ситуации разделения вычислительных мощностей
- только одна транзакция или один клиент может удерживать блокировку на конкретный ресурс или объект, чтобы предотвратить конкурентную запись в него и его порчу
- только один пользователь может зарегистрировать конкретное имя пользователя, поскольку оно должно идентифицировать пользователя уникальным образом

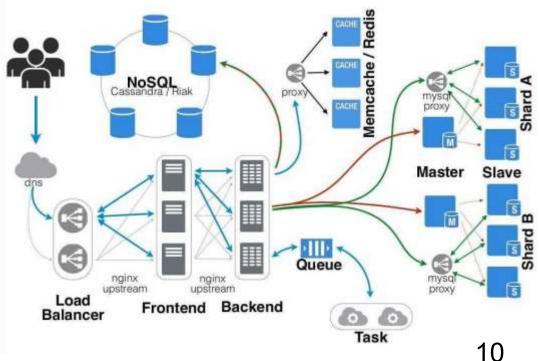
Случай, когда узел продолжает вести себя как «избранный», несмотря на то, что кворум остальных узлов объявил его неработающим, может привести к проблемам в недостаточно тщательно спроектированной системе

Подобный узел способен отправлять сообщения другим узлам в качестве самозваного «избранного», и если другие узлы с этим согласятся, то система в целом может начать работать неправильно.

### HighLoad: архитектурные паттерны

- сервисно-ориентированная архитектура
- вертикальное масштабирование
- горизонтальное масштабирование
- отложенные вычисления
- асинхронная обработка
- конвейерная обработка
- использование толстого клиента
- кеширование
- функциональное разделение
- шардинг
- виртуальные шарды
- центральный диспетчер
- репликация
- партиционирование
- кластеризация
- денормализация
- введение избыточности
- нереляционные субд
- толстый клиент
- параллельное выполнение





<u>HighLoad (хабрахабр)</u>

#### Терминология: онлайн и офлайн

Термины **онлайн** (<u>англ.</u> *online*) и **офлайн** (<u>англ.</u> *offline*) имеют значение в отношении к <u>компьютерным технологиям</u> и <u>телекоммуникациям</u>:

- онлайн указывает на состояние подключения, а
- офлайн указывает на отключенное состояние

В современной терминологии это обычно относится к <u>интернет-соединению</u>, но (особенно когда оно выражено «on line») может относиться к любому элементу оборудования или функциональному блоку, который подключен к более крупной системе

Быть онлайн означает, что оборудование или подсистема подключены или что они готовы к использованию

Понятие «онлайн» также описывает действия и данные, доступные в интернете, например: «<u>онлайн-идентификация</u> », «<u>онлайн-игры</u>», «<u>онлайн-шоппинг</u>», «<u>онлайн-банкинг</u>» и «<u>онлайн обучение</u>»

Аналогичное значение также дают префиксы «кибер» и «е», как в словах «киберпространство », «киберпреступность», «электронная почта» и «электронная коммерция»

#### Терминология: системы реального времени

Система реального времени (СРВ) — это <u>система</u>, которая должна реагировать на события во внешней по отношению к системе среде или воздействовать на среду в рамках требуемых временных ограничений

Другими словами, обработка информации системой должна производиться за определённый конечный период времени, чтобы поддерживать постоянное и своевременное взаимодействие со средой

Естественно, что масштаб времени контролирующей системы и контролируемой ей среды должен совпадать

Под *реальным временем* понимается количественная характеристика, которая может быть измерена реальными физическими <u>часами</u>, в отличие от *погического времени*, определяющего лишь качественную характеристику, выражаемую относительным порядком следования событий

Говорят, что система работает в *режиме реального времени*, если для описания работы этой системы требуются количественные временные характеристики

#### Терминология: системы реального времени

Процессы (задачи) систем реального времени могут иметь следующие характеристики и связанные с ними ограничения:

- <u>дедлайн</u> (<u>англ.</u> *deadline*) критический **срок обслуживания**, предельный срок завершения какой-либо работы
- <u>латентность</u> (<u>англ.</u> *latency*) **время отклика** (время задержки) системы на внешние события
- <u>джиттер</u> (<u>англ.</u> *jitter*) **разброс значений** времени отклика

#### Можно различить:

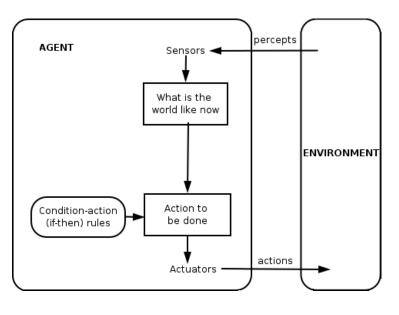
- джиттер запуска (англ. release jitter) период времени от готовности к исполнению до начала собственно исполнения задачи и
- джиттер вывода (англ. output jitter) задержка по окончании выполнения задачи

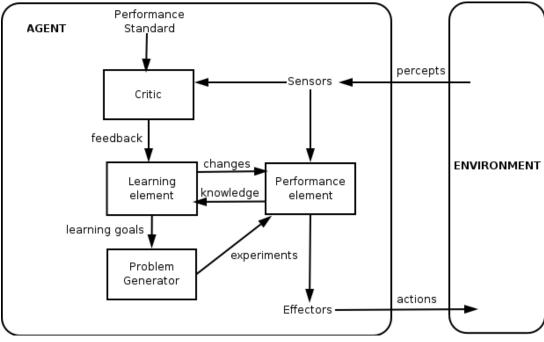
События реального времени могут относиться к одной из трёх категорий:

- асинхронные события полностью непредсказуемые события
- **синхронные** *события* предсказуемые события, случающиеся с определённой регулярностью
- **изохронные** *события* регулярные события (разновидность асинхронных), случающиеся в течение интервала времени

#### Терминология: интеллектуальные агенты

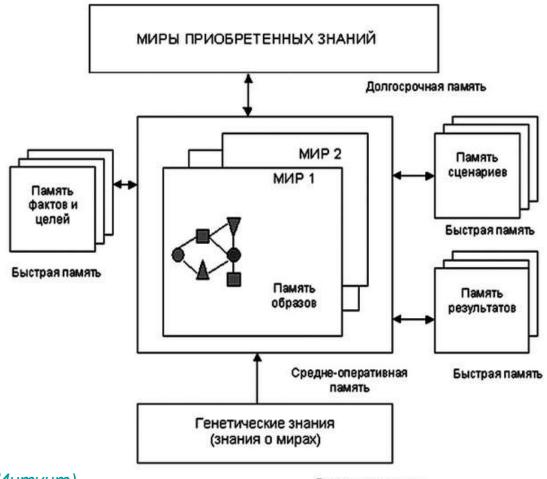
**Многоагентная система (MAC, англ. Multi-agent system)** — это система, образованная несколькими взаимодействующими <u>интеллектуальными агентами</u>. Многоагентные системы могут быть использованы для решения таких проблем, которые сложно или невозможно решить с помощью одного агента или монолитной системы.





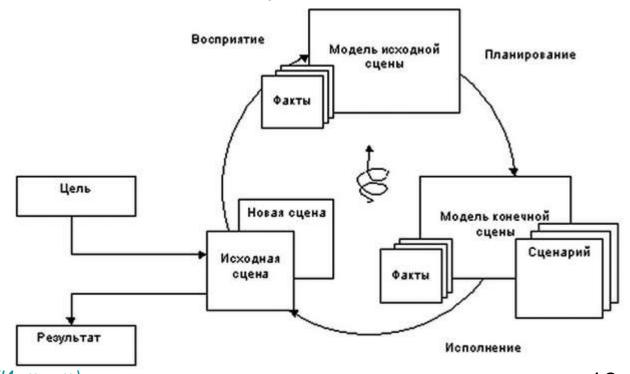
#### Терминология: интеллектуальные агенты

Концепция "Агентов и Миров" реализует формирование общего мира деятельности кооперирующих сторон и миров деятельности каждой из них, путем создания единой комплексной среды. В этом подходе мир действий — это модель среды деятельности, базирующаяся на знаниях



#### Терминология: интеллектуальные агенты

Важным элементом при создании мультиагентных систем является язык коммуникации агентов — Agent Communication Language, который определяет типы сообщений, которыми могут обмениваться агенты. В рамках парадигмы коммуникации между агентами, кооперация между ними достигается за счет АСL, языка контента и онтологии, которые определяют набор базовых концепций, используемых в сообщениях кооперации. Онтология здесь выступает синонимом понятия API (Application Programming Interface), т.е. она определяет конкретный интерфейс интеллектуальных агентов.



<u>МАС</u> <u>Мультиагентые системы (Интуит)</u>

16

# Терминология: интернет вещей (IoT)

**Интернет вещей** (англ. Internet of Things, IoT) — концепция вычислительной сети физических предметов («вещей»), оснащённых встроенными технологиями для взаимодействия друг с другом или с внешней средой, рассматривающая организацию таких сетей как явление, способное перестроить экономические и общественные процессы, исключающее из части действий и операций необходимость участия человека

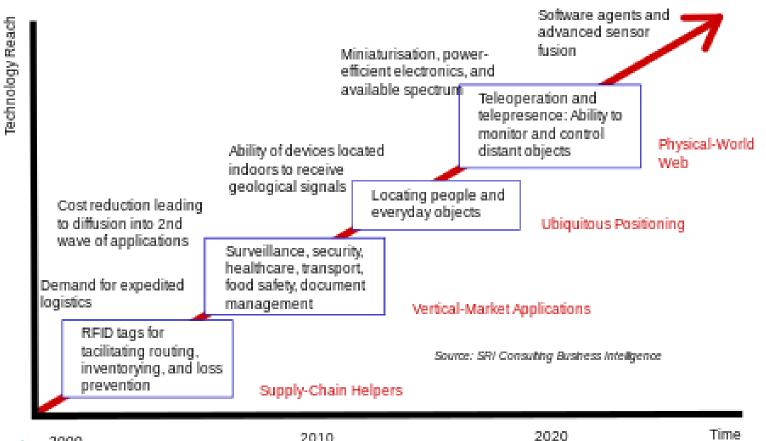
Концепция сформулирована в 1999 году как осмысление перспектив широкого применения средств радиочастотной идентификации для взаимодействия физических предметов между собой и с внешним окружением

Наполнение концепции «интернета вещей» многообразным технологическим содержанием и внедрение практических решений для её реализации начиная с 2010-х годов считается устойчивой тенденцией в информационных технологиях, прежде всего, благодаря повсеместному распространению <u>беспроводных сетей</u>, появлению <u>облачных вычислений</u>, развитию технологий межмашинного взаимодействия, началу активного перехода на <u>IPv6</u> и освоению программно-конфигурируемых сетей

# Терминология: интернет вещей (IoT)

**Киберне́тика** (от др.-греч. κυβερνητική — «искусство управления») — наука об общих закономерностях получения, хранения, передачи и преобразования информации в сложных управляющих системах, будь то машины, живые организмы или общество

#### Technology roadmap: The Internet of Things

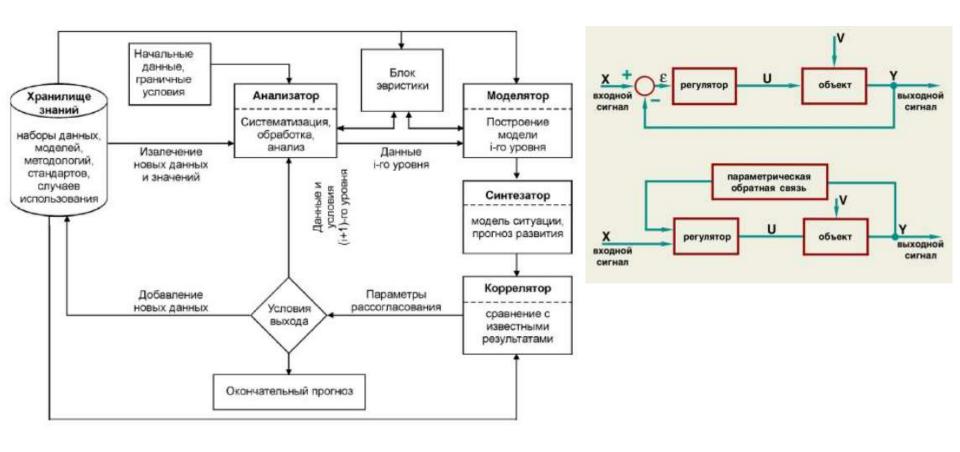


Кибернетика IoT

2000

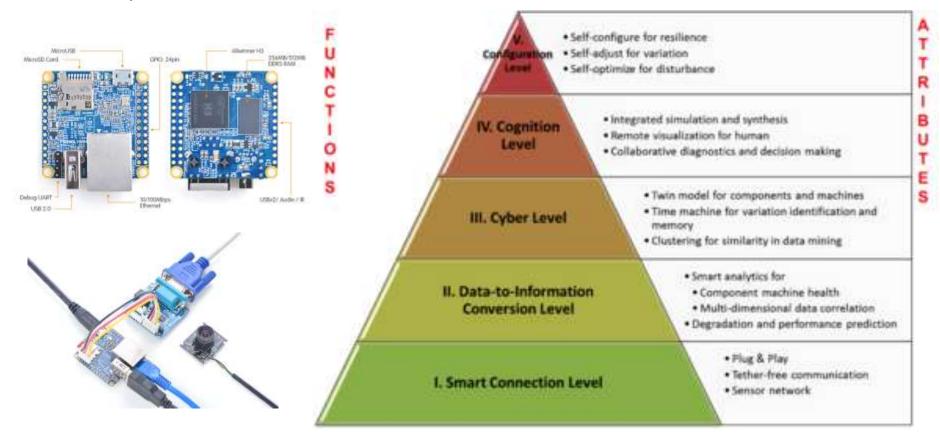
# Терминология: интернет вещей (IoT)

Кибернетика включает изучение <u>обратной связи</u>, <u>чёрных ящиков</u> и производных <u>концептов</u>, таких как <u>управление</u> и <u>коммуникация</u> в живых организмах, <u>машинах</u> и <u>организациях</u>, включая <u>самоорганизации</u>



# Терминология: индустриальный интернет вещей (IIoT)

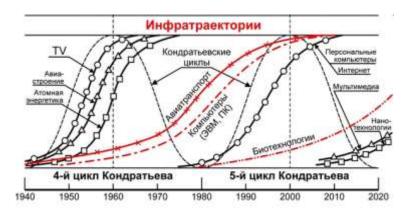
Промышленный Интернет вещей (англ. *Industrial Internet of Things, IIoT*) - это концепция, при которой различные промышленные устройства, такие как датчики или оборудование, объединены в сеть посредством использования сети Интернет.

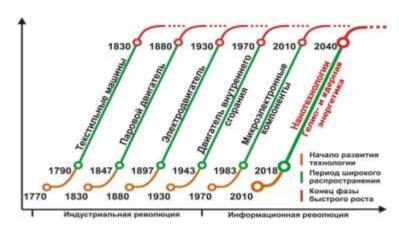


## Терминология: технологический уклад

**Технологический уклад** — экономический термин, обозначающий установившийся порядок чего-либо, характеризующийся единым техническим уровнем составляющих его производств, связанных потоками качественно однородных ресурсов, опирающихся на общие ресурсы квалифицированной рабочей силы, общий научно-технический потенциал.

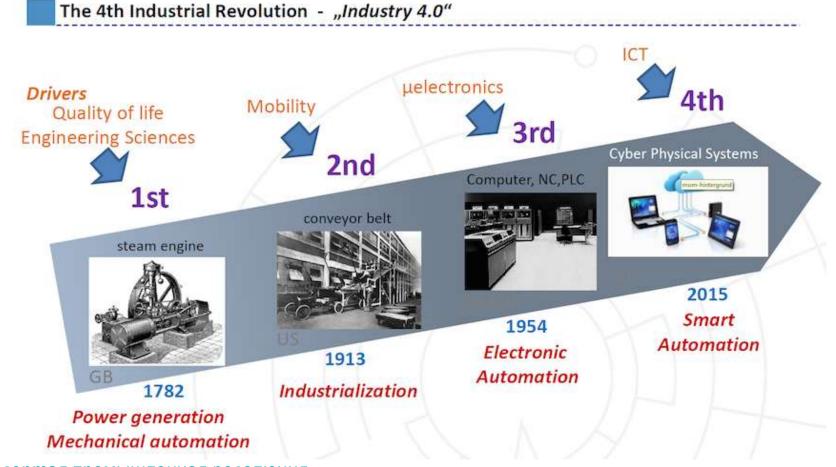
Основной особенностью текущего, пятого технологического уклада (1985-2035гг.), является массовый переход от функционирующих разрозненно фирм к появлению единой сети крупных и мелких компаний, соединенных электронными коммуникациями на основе сети Интернет, осуществляющих тесное взаимодействие в области технологий, контроля качества продукции, планирования инноваций и т.д.





#### Терминология: Индустрия 4.0

Четвёртая промышленная революция (<u>англ.</u> The Fourth Industrial Revolution) — прогнозируемое событие, массовое внедрение <u>киберфизических систем</u> в <u>производство</u> (индустрия 4.0), обслуживание человеческих потребностей, включая <u>быт, труд</u> и <u>досуг</u>



#### Терминология: цифровое производство

**Цифровое производство** — интегрированная компьютерная система, включающая в себя средства: численного моделирования, трехмерной (3D) визуализации, инженерного анализа и совместной работы, предназначенные для разработки конструкции изделий и технологических процессов их изготовления

Цифровое производство начиналось с таких инициатив, как конструирование с учетом технологичности (DFM), компьютерно-интегрированное производство (СІМ), гибкое производство, бережливое производство и других, направленных на расширение совместной работы при конструкторско-технологической

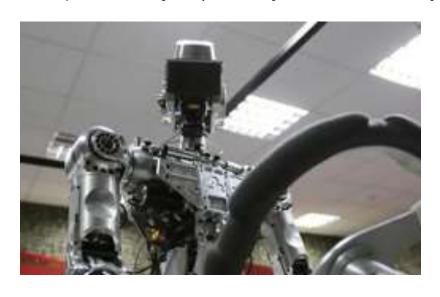
подготовке производства изделий

#### Терминология: робототехника

Робототе́хника (от <u>робот</u> и <u>техника</u>; <u>англ.</u> *robotics* — **роботика**, *роботехника*) — прикладная <u>наука</u>, занимающаяся разработкой автоматизированных технических систем и являющаяся важнейшей технической основой интенсификации производства

Робототехника опирается на такие дисциплины, как <u>электроника</u>, <u>механика</u>, <u>телемеханика</u>, <u>информатика</u>, а также <u>радиотехника</u> и <u>электротехника</u>.

Выделяют строительную, промышленную, бытовую, авиационную и экстремальную (военную, космическую, подводную) робототехнику





# Лекция 18 «Аналитические и экспертные системы»

Овчинников П.Е. МГТУ «СТАНКИН», ст.преподаватель кафедры ИС

#### Терминология: OLTP-системы

**Транза́кция** (англ. *transaction*) — группа последовательных операций с <u>базой</u> данных, которая представляет собой логическую единицу работы с данными

Транзакция может быть выполнена либо целиком и успешно, соблюдая целостность данных и независимо от параллельно идущих других транзакций, либо не выполнена вообще, и тогда она не должна произвести никакого эффекта

**OLTP** (<u>англ.</u> Online Transaction Processing), транзакционная система — обработка транзакций в реальном времени.

Способ организации базы данных, при котором система работает с небольшими по размерам транзакциями, но идущими большим потоком, и при этом клиенту требуется от системы минимальное время отклика

OLTP-системы предназначены для:

- ввода
- структурированного хранения
- обработки

информации (операций, документов) в режиме реального времени

#### Терминология: OLTP-системы

ОLTР-приложениями охватывается широкий спектр задач во многих отраслях — <u>автоматизированные банковские системы</u>, <u>ERP-системы (системы планирования ресурсов предприятия)</u>, банковские и биржевые операции, в промышленности — регистрация прохождения детали на <u>конвейере</u>, фиксация в статистике посещений очередного посетителя веб-сайта, автоматизация бухгалтерского, складского учёта и учёта документов и т. п.

Приложения OLTP, как правило, автоматизируют структурированные, повторяющиеся задачи обработки данных, такие как ввод заказов и банковские транзакции. OLTP-системы проектируются, настраиваются и оптимизируются для выполнения максимального количества транзакций за короткие промежутки времени. Как правило, большой гибкости здесь не требуется, и чаще всего используется фиксированный набор надёжных и безопасных методов ввода, модификации, удаления данных и выпуска оперативной отчётности

Показателем эффективности является количество **транзакций**, выполняемых **за секунду**. Обычно аналитические возможности OLTP-систем сильно ограничены (либо вообще отсутствуют).

27

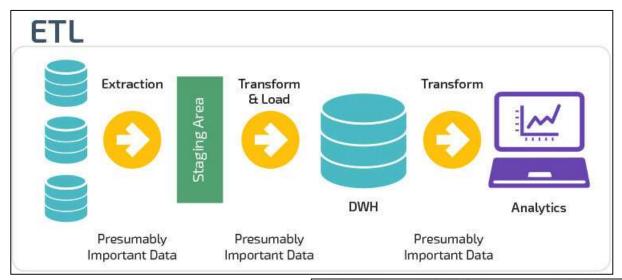
#### Терминология: OLAP-системы

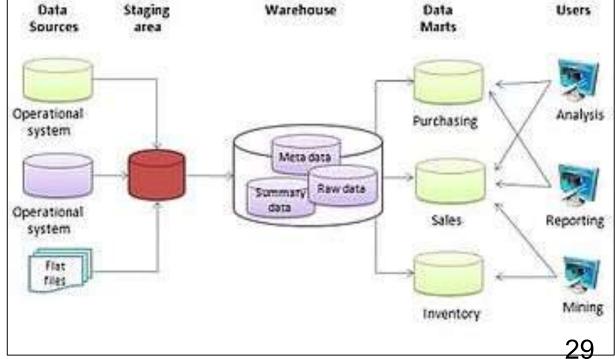
**OLAP** (англ. online analytical processing, аналитическая обработка в реальном времени) — технология обработки данных, заключающаяся в подготовке **суммарной (агрегированной) информации** на основе больших массивов данных, структурированных по многомерному принципу.

#### OLTP vs. OLAP Differences

	OLTP	OLAP
Organization	By workflow per application	By dimension and business subject
Data Retention	Short term (2-6 months)	Long term (2-5 years)
Data Integration	Minimal or none	High, as part of ETL process
Data Storage	Gigabytes	Terabytes
Use	Real time Write & update Evenly distributed usage Transactional data	Batch load Reporting, read-only Spiked usage (based on time of warehouse loads)

#### Терминология: OLAP-системы





#### Терминология: OLAP-системы

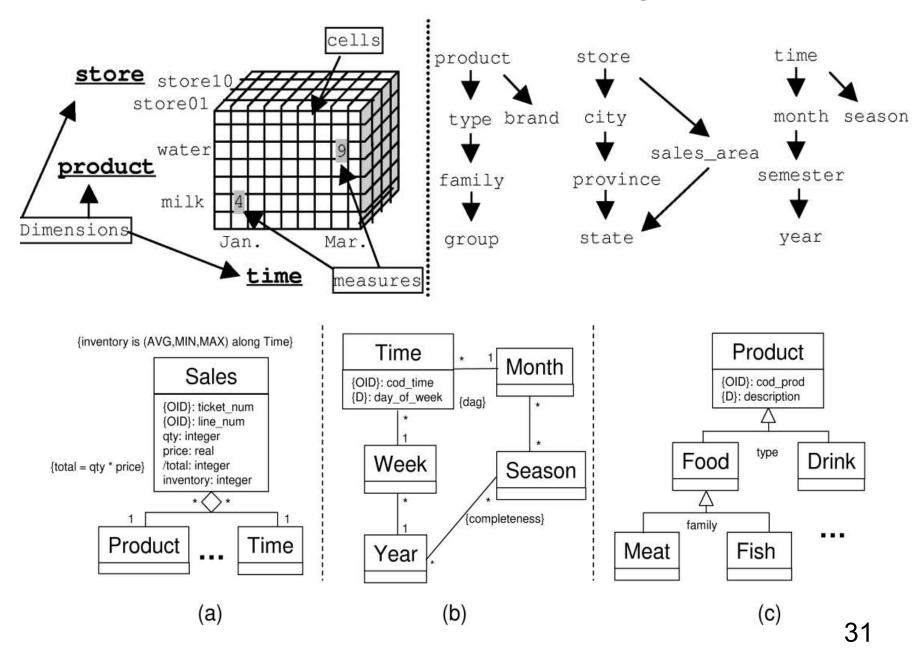
Реализации технологии OLAP являются компонентами программных решений класса <u>Business Intelligence</u>

**Многомерное моделирование** является методом моделирования и визуализации данных как множества числовых или лингвистических показателей или параметров (measures), которые описывают общие аспекты деятельности организации

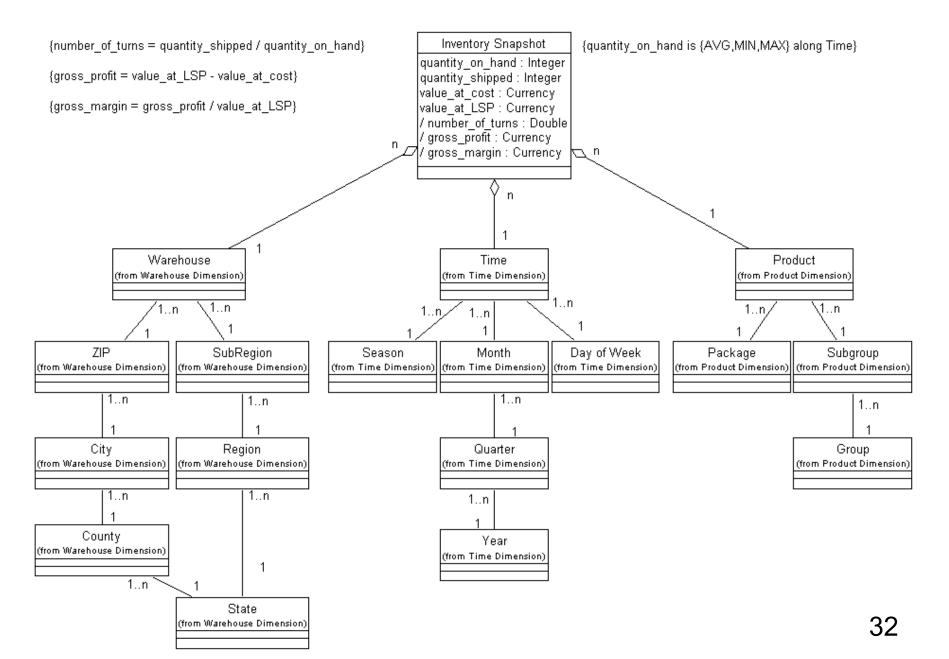
Метод многомерного моделирования базируется на следующих основных понятиях:

- Факт (Fact) набор связанных элементов данных, содержащих метрики и описательные данные.
- **Атрибут (Attribute)** описание характеристики реального объекта предметной области.
- Измерение (Dimension) интерпретация факта с некоторой точки зрения в реальном мире.
- Параметр, метрика или показатель (Measure) числовая характеристика факта
- Гранулированность (Granularity) уровень детализации данных.

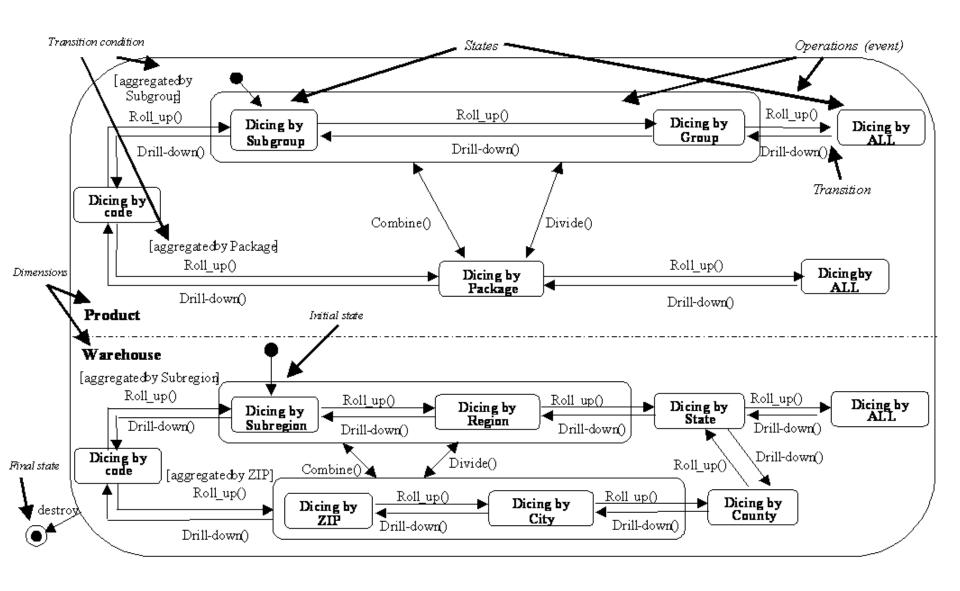
# Терминология: OLAP-куб



#### Терминология: измерение



# Терминология: roll up и drill down

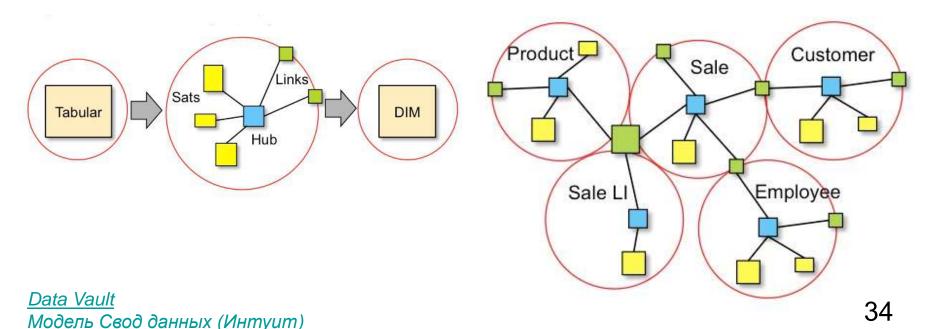


#### Нормальные формы: Data Vault

**Модель Data Vault** представляет собой набор связанных между собой нормализованных таблиц, ориентированных на хранение детализированной информации с возможностью отслеживания происхождения данных и поддерживающих одну или несколько областей бизнеса.

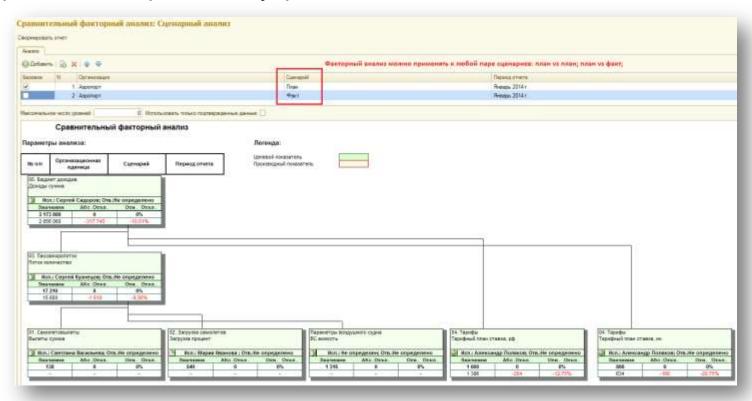
В модели Data Vault используется всего три типа таблиц:

- Hub обеспечивает представление функциональных областей предметной области
- Link обеспечивает транзакционную связь между Hub-таблицами
- Satellite предоставляет детализацию первичного ключа Hub-таблицы



#### Терминология: СРМ-системы

Управление эффективностью деятельности организации (английские термины СРМ, ВРМ, ЕРМ) — это набор управленческих процессов (планирования, организации выполнения, контроля и анализа), которые позволяют бизнесу определить стратегические цели и затем оценивать и управлять деятельностью по достижению поставленных целей при оптимальном использовании имеющихся ресурсов. Это система управления, построенная на принципах управления стоимостью бизнеса.





#### Терминология: консолидация

**Консолидация данных** — комплекс методов и процедур, направленных на **извлечение** данных из различных источников, **обеспечение** необходимого уровня их информативности и **качества**, преобразование в **единый формат**, в котором они могут быть загружены в хранилище данных или аналитическую систему

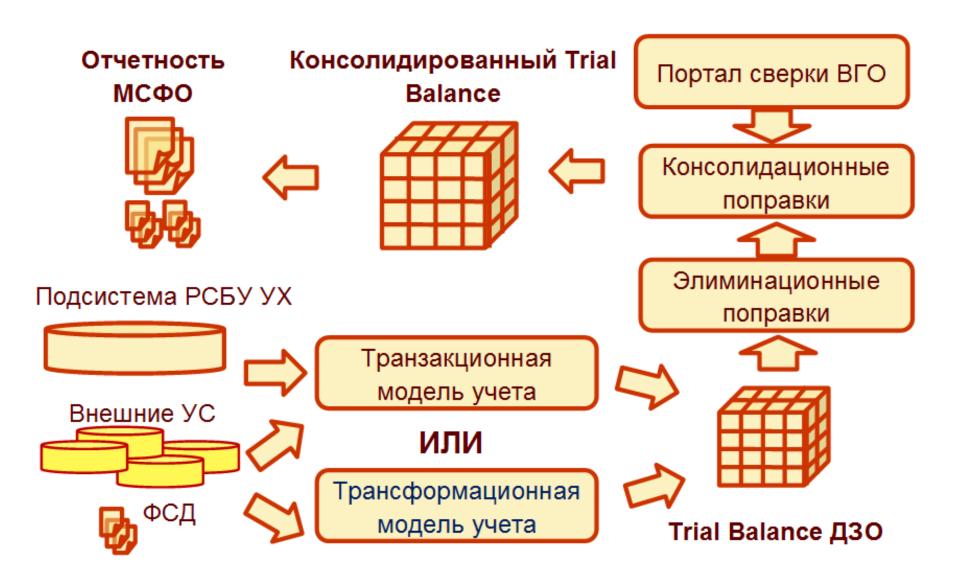
**Консолидированная (сводная) отчетность** - это система показателей, отражающих финансовое положение и финансовые результаты предприятия по истечении отчетного периода и включающая данные о зависимых обществах, являющихся юридическими лицами по законодательству места их государственной регистрации

**Трансформация** бухгалтерской (финансовой) отчетности - это процесс составления отчетности в соответствии с МСФО путем перегруппировки учетной информации и корректировки статей отчетности, подготовленной по правилам российской системы бухгалтерского учета

Элиминация - это процесс исключение внутригрупповых операций при консолидации отчётности

Консолидация (1С)

#### Терминология: консолидация



<u>Консолидация (1C)</u>

#### Терминология: экспертные системы

**Экспертная система** (<u>англ.</u> *expert system*) — компьютерная система, способная частично заменить специалиста-эксперта в разрешении проблемной ситуации.

Современные экспертные системы начали разрабатываться исследователями <u>искусственного интеллекта</u> в <u>1970-х годах</u>, а в <u>1980-х годах</u> получили коммерческое подкрепление

Важнейшей частью экспертной системы являются <u>базы знаний</u> как модели поведения <u>экспертов</u> в определённой области знаний с использованием процедур логического вывода и <u>принятия решений</u>, иными словами, <u>базы знаний</u> — совокупность фактов и правил логического вывода в выбранной предметной области деятельности

Экспертная система анализирует ситуацию и даёт рекомендации по разрешению проблемы

Как правило, база знаний экспертной системы содержит факты (статические сведения о предметной области) и правила— набор инструкций, применяя которые к известным фактам можно получать новые факты

#### Терминология: СППР

Система поддержки принятия решений (СППР) (англ. Decision Support System, DSS) — компьютерная автоматизированная система, целью которой является помощь людям, принимающим решение в сложных условиях для полного и объективного анализа предметной деятельности

СППР возникли в результате слияния управленческих <u>информационных</u> <u>систем</u> и <u>систем управления базами данных</u> и используют различные методы:

- информационный поиск,
- интеллектуальный анализ данных,
- поиск знаний в базах данных,
- рассуждение на основе прецедентов,
- имитационное моделирование,
- эволюционные вычисления и генетические алгоритмы,
- нейронные сети,
- ситуационный анализ,
- когнитивное моделирование и др.

Некоторые из этих методов были разработаны в рамках <u>искусственного</u> <u>интеллекта</u>

<u>СППР (Википедия)</u>

**Машинное обучение** (англ. Machine Learning) — обширный подраздел <u>искусственного интеллекта</u>, изучающий методы построения <u>алгоритмов</u>, способных обучаться

Различают два типа обучения:

- *Обучение по прецедентам*, или *индуктивное обучение*, основано на выявлении общих закономерностей по частным <u>эмпирическим данным</u>
- *Дедуктивное обучение* предполагает формализацию знаний экспертов и их перенос в компьютер в виде <u>базы знаний</u>

Дедуктивное обучение принято относить к области <u>экспертных систем</u>, поэтому термины *машинное обучение* и *обучение по прецедентам* можно считать синонимами

Обучение с учителем (supervised learning) — наиболее распространённый случай. Каждый прецедент представляет собой пару «объект, ответ». Требуется найти функциональную зависимость ответов от описаний объектов и построить алгоритм, принимающий на входе описание объекта и выдающий на выходе ответ. Функционал качества обычно определяется как средняя ошибка ответов, выданных алгоритмом, по всем объектам выборки.

<u>Машинное обучение</u>

Задача классификации (classification) отличается тем, что множество допустимых ответов конечно. Их называют метками классов (class label). Класс — это множество всех объектов с данным значением метки

**Задача** <u>регрессии</u> (regression) отличается тем, что допустимым ответом является действительное число или числовой вектор.

Задача ранжирования (learning to rank) отличается тем, что ответы надо получить сразу на множестве объектов, после чего отсортировать их по значениям ответов

Может сводиться к задачам классификации или регрессии. Часто применяется в <u>информационном поиске</u> и <u>анализе текстов</u>

Задача прогнозирования (forecasting) отличается тем, что объектами являются отрезки временных рядов, обрывающиеся в тот момент, когда требуется сделать прогноз на будущее Для решения задач прогнозирования часто удаётся приспособить методы

регрессии или классификации, причём во втором случае речь идёт скорее о задачах <u>принятия решений</u>

<u>Машинное обучение</u> 4°

Обучение без учителя (unsupervised learning). В этом случае ответы не задаются, и требуется искать зависимости между объектами.

Задача кластеризации (clustering) заключается в том, чтобы сгруппировать объекты в кластеры, используя данные о попарном сходстве объектов. Функционалы качества могут определяться по-разному, например, как отношение средних межкластерных и внутрикластерных расстояний.

Задача поиска ассоциативных правил (association rules learning).

Исходные данные представляются в виде признаковых описаний. Требуется найти такие наборы признаков, и такие значения этих признаков, которые особенно часто (неслучайно часто) встречаются в признаковых описаниях объектов

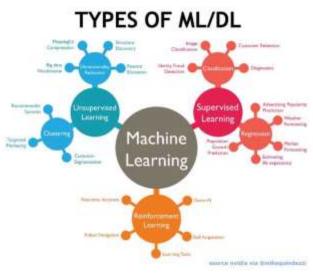
Задача фильтрации выбросов (outliers detection) — обнаружение в обучающей выборке небольшого числа нетипичных объектов. В некоторых приложениях их поиск является самоцелью (например, обнаружение мошенничества). В других приложениях эти объекты являются следствием ошибок в данных или неточности модели, то есть шумом, мешающим настраивать модель, и должны быть удалены из выборки

<u>Машинное обучение</u> 42

**Задача построения доверительной области** (quantile estimation) — области минимального объёма с достаточно гладкой границей, содержащей заданную долю выборки

Задача сокращения размерности (dimensionality reduction) заключается в том, чтобы по исходным признакам с помощью некоторых функций преобразования перейти к наименьшему числу новых признаков, не потеряв при этом никакой существенной информации об объектах выборки

Задача заполнения пропущенных значений (missing values) — замена недостающих значений в матрице объекты—признаки их прогнозными значениями



43